

Percepção dos Brasileiros Acerca da Democracia

Uma análise exploratória correlacionando opinião declarada (CESOP) e comportamento eleitoral observado (TSE 2022)

Disciplina: Ciência de Dados — Projeto I (EDA, *Exploratory Data Analysis*) **Instituição:** Instituto Mauá de Tecnologia (IMT) **Tema:** Percepção dos Brasileiros Acerca da Democracia **Bases:** CESOP/04832 (pesquisa de opinião) × TSE (perfil de comparecimento e abstenção, Eleições Gerais de 2022) **Ano:** 2026

Resumo

Este trabalho investiga a percepção dos brasileiros sobre democracia e participação política, correlacionando uma **pesquisa de opinião** do Centro de Estudos de Opinião Pública (CESOP, estudo 04832, $n = 2.000$ respondentes) com uma **base pública de comportamento eleitoral** do Tribunal Superior Eleitoral (TSE) — o perfil de comparecimento e abstenção das Eleições Gerais de 2022 (8.785.738 linhas-detelhe; 311,5 milhões de eleitores aptos). O pipeline de dados foi construído em Python (pandas, NumPy, pyreadstat) e as análises empregaram visualizações estatísticas (barras empilhadas 100%, *heatmaps*, dispersão, linhas de eixo duplo) e a correlação de Spearman entre agregados. O principal achado é que **a escolaridade — e não a região — é o eixo que organiza o engajamento político**: é a única dimensão em que percepção declarada e comportamento real se **alinham perfeitamente** ($\rho = 1,00$), enquanto, por região, as duas dimensões chegam a se **opor** ($\rho = -0,30$). A **renda reproduz o mesmo gradiente** de forma independente, e a **idade** funciona como um segundo eixo estrutural, desenhando um **U-invertido** (engajamento concentrado na meia-idade, queda nas duas pontas) que reaparece em três medidas distintas. Observa-se, ainda, um quadro consistente de **baixo engajamento participativo declarado** (78% sem vontade de participar da política local), convergente em três perguntas independentes da pesquisa e coerente com a preferência, no caso das *fake news*, por **soluções diretas (punir) em vez de processuais (regular)**.

1. Introdução

1.1 Contexto e motivação

A democracia brasileira combina **voto obrigatório** (para a maioria dos cidadãos) com níveis variados de engajamento político voluntário. Essa combinação levanta uma questão central: **o ato de votar — muitas vezes uma obrigação legal — reflete uma disposição genuína de participar da vida política?** Pesquisas de opinião capturam a *percepção* e a *disposição declaradas*; registros eleitorais capturam o *comportamento efetivo*. Analisar as duas dimensões em conjunto permite verificar se elas convergem ou divergem — e, quando divergem, em quais grupos isso ocorre.

1.2 Problema de pesquisa

O projeto parte da seguinte pergunta norteadora:

Grupos com maior participação eleitoral real também demonstram maior disposição declarada para participar da política? Em que dimensões (região, escolaridade, idade) percepção e

1.3 Objetivos

Objetivo geral. Realizar uma análise exploratória da percepção dos brasileiros sobre democracia e participação política, correlacionando-a com o comportamento eleitoral observado em 2022.

Objetivos específicos:

1. Estruturar e limpar a base de opinião (CESOP) e a base eleitoral (TSE), tornando-as comparáveis por dimensões comuns.
2. Caracterizar a amostra e descrever as percepções declaradas (lembrança de voto, prioridades políticas, combate a *fake news* e vontade de participação).
3. Descrever o comparecimento e a abstenção eleitoral de 2022 por região, idade e escolaridade.
4. **Cruzar** percepção declarada (CESOP) e comportamento real (TSE) por grupos sociodemográficos, identificando padrões de convergência e divergência.

1.4 Perguntas analíticas derivadas

#	Pergunta	Seção
Q1	Qual o perfil da amostra e o que os brasileiros declaram lembrar/priorizar/desejar?	3.1–3.5
Q2	Como variam comparecimento e abstenção por região, idade e escolaridade?	3.6
Q3	Disposição declarada e comparecimento real andam juntos, por região?	3.7.1 / 3.7.4
Q4	E por escolaridade? E por faixa etária?	3.7.2 / 3.7.3
Q5	A amostra de opinião é representativa do eleitorado?	3.7.5

2. Materiais e Métodos

2.1 Fontes de dados

2.1.1 Base principal — CESOP/04832 (pesquisa de opinião)

- **Origem:** Centro de Estudos de Opinião Pública (CESOP/UNICAMP), estudo **04832**.
- **Formato:** arquivo SPSS (.SAV), lido com a biblioteca `pyreadstat`, que retorna o `DataFrame` e um objeto de metadados com os rótulos das variáveis e os mapeamentos código→categoria embutidos no arquivo.
- **Dimensão:** **2.000 respondentes × 30 variáveis**.

- **Blocos de variáveis utilizados:**

Variável	Descrição
SEX0, FX_ID, ESCOLARIDADE, RACA, RELIGIAO	Perfil demográfico
REND1, REND2	Renda pessoal e familiar (em salários mínimos)
REGIAO, COND, PORTE	Localização e porte do município
P_01A, P_01B, P_01C	Lembrança do voto em 2022 (dep. estadual, federal, senador)
P_02_1, P_02_2, P_02_3	Prioridades políticas (1ª, 2ª e 3ª escolhas)
P_03_1 ... P_03_6	Medidas consideradas úteis contra <i>fake news</i> (múltipla escolha)
P_04	Vontade de participar da vida política local

2.1.2 Base complementar — TSE (comportamento eleitoral)

- **Origem:** Tribunal Superior Eleitoral — *Perfil do Eleitorado: Comparecimento e Abstenção, Eleições Gerais de 2022*, arquivo nacional (...BRASIL.csv).
- **Formato:** CSV (~2,3 GB), separador ;, encoding latin1 (padrão das bases do TSE).
- **Dimensão após limpeza:** 8.785.738 linhas-detalhe (combinações de UF × município × zona × perfil demográfico).
- **Totais nacionais (2022):** 311.513.866 aptos; 247.332.217 comparecimentos; 64.181.649 abstenções → comparecimento de 79,40%.
- **Variáveis utilizadas:** SG_UF, NM_MUNICIPIO, DS_GENERO, DS_ESTADO_CIVIL, DS_FAIXA_ETARIA, DS_GRAU_ESCOLARIDADE, DS_COR_RACA, QT_APTOS, QT_COMPARECIMENTO, QT_ABSTENCAO.

Conexão conceitual entre as bases: a CESOP mede opinião e disposição declarada; o TSE mede comportamento eleitoral real. A ponte entre elas é feita por dimensões comuns (região, escolaridade, faixa etária), permitindo uma **comparação ecológica** — entre grupos agregados, **não** entre os mesmos indivíduos.

2.2 Ferramentas e ambiente

- **Linguagem:** Python 3.
- **Bibliotecas:** pandas e numpy (manipulação), pyreadstat (leitura de .SAV), matplotlib e seaborn (visualização).
- **Formato intermediário:** Parquet, que preserva os tipos categóricos sem recodificação na releitura e reduz o tamanho em disco.
- **Reprodutibilidade:** os notebooks detectam automaticamente o ambiente (Google Colab × local) e ajustam os caminhos — atendendo ao requisito de execução 100% no Colab.

2.3 Pipeline de preparação dos dados (Notebook 01)

O primeiro notebook não contém análise: dedica-se inteiramente à **preparação reprodutível**, em duas frentes.

CESOP: 1. **Carregamento** do .SAV com `pyreadstat` (dados + metadados). 2. **Padronização de nomes** das variáveis de pergunta (`P1A` → `P_01A`) e conversão de `DATA_ENTREVISTA` para `datetime`. 3. **Tratamento de não-resposta:** o código 99 ("Não sabe/Não respondeu") é convertido em `NaN`. A substituição é feita **por coluna** (não globalmente), de modo a **preservar** o código 98 de `REND1/REND2` ("Não tem rendimento"), que é uma **categoria válida** — decisão documentada em uma tabela explícita para evitar uma generalização que apagaria esse valor. 4. **Rotulagem:** aplicação dos *value labels* e conversão para o tipo `category`, feita **após** a limpeza de 99 para preservar os `NaN` recém-inseridos. 5. **Variáveis derivadas:** agregação dos 16 níveis de `ESCOLARIDADE` em **5 grupos ordenados** (`ESCOL_GRUPO`: baixa escolaridade → fundamental → médio → superior incompleto → superior completo) e das faixas de renda em **5 faixas** (`RENDA_PESSOAL`, `RENDA_FAMILIAR`). Inclui-se uma **validação de cobertura** que detecta rótulos não mapeados (evita perdas silenciosas por divergência de grafia ou acentuação).

TSE: 1. **Carregamento otimizado:** leitura **apenas das colunas necessárias** (`usecols`) — essencial para caber na memória do Colab dado o volume de 2,3 GB. 2. **Limpeza:** remoção de combinações com `QT_APTOS = 0` (dividiriam por zero nas taxas), normalização de strings e conversão para `category`. 3. **Variáveis derivadas:** `TAXA_COMPARECIMENTO` e `TAXA_ABSTENCAO` (proporções em `[0, 1]`) e `REGIAO` (derivada da UF pela categorização do IBGE). 4. **Agregações:** dois recortes — por **UF** (`df_tse_uf`) e por **perfil demográfico nacional** (`df_tse_perfil`). As taxas agregadas usam a **soma** das contagens (média ponderada por eleitor), e **não** a média das taxas-linha — evitando que zonas pequenas distorçam o indicador. 5. **Validação:** `assert` garante que todas as taxas estão no intervalo `[0, 1]` antes do salvamento.

Saídas: `cesop_clean.parquet`, `tse_clean.parquet`, `tse_uf.parquet`, `tse_perfil.parquet` e `cesop_labels.json`.

2.4 Harmonização entre as bases

Como CESOP e TSE adotam convenções diferentes, foram criadas tabelas de correspondência (Notebook 02):

- **Região:** unificação de grafias (ex.: `NORDESTE` → `Nordeste`).
- **Escaridade:** os níveis do TSE são mapeados para os 5 grupos do CESOP.
- **Faixa etária:** as idades do TSE são *bucketizadas* nas mesmas faixas do CESOP.

2.5 Técnicas estatísticas e de visualização

- **Distribuições univariadas:** frequências e percentuais, com `n` explícito.
- **Tabelas cruzadas** (`crosstab`) normalizadas por linha (composição dentro de cada grupo).
- **Visualizações:** barras horizontais, **barras empilhadas 100%**, **gráficos de pizza**, **heatmaps**, **dispersão** (`scatter`) com rótulos por grupo e **linhas com eixo duplo** (`twinx`).
- **Correlação de Spearman (ρ):** medida de associação **monotônica** entre os agregados, apropriada para poucos pontos e relações não necessariamente lineares. Usada nos cruzamentos CESOP × TSE.
- **Cuidados metodológicos:** denominadores corretos em perguntas de múltipla escolha (percentuais sobre o **total de menções**, não de respondentes), ordenação semântica das categorias ordinais e sinalização explícita de recortes com **baixo `n`**.

3. Resultados e Discussão

Todos os percentuais e coeficientes a seguir foram obtidos diretamente das análises dos notebooks. Valores precedidos de "≈" foram lidos das figuras geradas.

3.1 Perfil da amostra (CESOP, n = 2.000)

- **Sexo:** 51,7% feminino, 48,3% masculino — equilibrado.
- **Faixa etária:** concentração em adultos — 25–34 anos (22,9%) e 35–44 anos (21,2%), somando 44,1%; jovens de 16–17 anos representam apenas 1,1%.
- **Raça/cor:** parda (46,0%) e branca (42,3%) somam quase 90%; preta (10,4%), amarela (0,9%) e indígena (0,4%) completam.
- **Escolaridade:** o ensino médio predomina (40,8%); a **baixa escolaridade é rara na amostra (3,2%)** — ponto decisivo, retomado na análise de representatividade (3.7.5).
- **Território:** a distribuição regional **acompanha o peso populacional do país** — Sudeste 43,2%, Nordeste 25,6%, Sul 15,2%, Norte e Centro-Oeste com 8,0% cada. Diferentemente da escolaridade, **geograficamente a amostra é plausível**, o que dá segurança às leituras por região.
- **Renda:** o perfil econômico é **predominantemente de baixa renda**. Na renda *pessoal*, 53,7% recebem até 1 salário mínimo (incluindo 12,6% sem rendimento) e apenas 5,2% ganham acima de 5 SM. Na renda *familiar*, a distribuição desloca-se para cima (58,8% entre 1 e 5 SM; faixa acima de 5 SM sobe para 12,0%), reflexo da soma de rendimentos no domicílio. Em ambas, o topo é residual (**acima de 20 SM: 0,4%–0,5%, ≈ 8 a 10 pessoas**) — o que **fundamenta as ressalvas de baixo n** feitas adiante.

3.2 Lembrança do voto em 2022 (P_01A/B/C)

Cargo	Lembra ("Sim")	Não lembra	Não votou
Deputado(a) estadual	29,8%	64,6%	5,5%
Deputado(a) federal	29,4%	65,0%	5,6%
Senador(a)	29,6%	64,9%	5,5%

Achado. A lembrança é **praticamente idêntica entre os três cargos** (≈ 30%): a maioria (≈ 65%) **não recorda em quem votou** para o Legislativo em 2022 — indício de baixo vínculo com a representação legislativa. Não há o gradiente "estadual < federal < senador" que se poderia supor. O conteúdo mais informativo está nos **recortes**:

1. **Gradiente socioeconômico — o padrão mais forte.** A lembrança **quase triplica** com a escolaridade: 16% (baixa) → 25% → 28% → 37% → **43%** (superior completo); e o mesmo gradiente reaparece na **renda pessoal**: 25% (até 1 SM) → 35% (1–5 SM) → **51%** (acima de 5 SM). Dois gradientes monotônicos e independentes na mesma direção tornam o achado robusto.
2. **Idade — relação em U-invertido, não linear.** A lembrança sobe até a meia-idade e recua entre os idosos: 17% (16–17) → 22% → 31% → **33% (35–44)** → 32% → 32% → 26% (65+). O pico está na faixa economicamente ativa; a lembrança é menor nos **dois extremos** etários.
3. **Voto facultativo nos 16–17 anos.** Nessa faixa, 35% declararam **não ter votado** (contra 6–9% nas demais), reflexo direto do voto facultativo abaixo dos 18 anos (*ressalva*: n = 23, valor ilustrativo).
4. **Norte fora da curva.** Entre regiões a lembrança é estável (≈ 25–30%), **exceto o Norte: 41%** (n = 160) — a mesma região com **baixo comparecimento real** no TSE, tensão explorada em 3.7.

3.3 Prioridades políticas (P_02)

Na **primeira escolha**, os temas mais citados foram:

Prioridade	% (1ª escolha)	n
Melhorar saúde	20,0%	400
Gerar empregos	14,7%	294
Reduzir desigualdades	14,3%	286
Reduzir violência	12,5%	250
Combater preconceitos	11,7%	233
Melhorar educação	11,1%	222
Preservar valores familiares	5,1%	103
Taxar grandes fortunas	2,2%	45
Ampliar participação política	2,0%	40
Defender igualdade de gênero	1,9%	38

O ranking muda conforme o critério. Quando se contam as **três menções** ($1^a + 2^a + 3^a$), **educação salta da 6ª para a 2ª posição** (15,8%), revelando-se um tema de "consenso secundário" — raramente a prioridade nº 1, mas citado com altíssima frequência logo em seguida. Já *reduzir desigualdades* cai (de 3ª para 5ª) e *combater preconceitos* recua — relatar os dois rankings evita uma leitura enganosa.

Gradiente socioeconômico (escolaridade e renda se espelham). Os *heatmaps* mostram gradientes monotônicos: *reduzir desigualdades* **sobe** com escolaridade (8% → ... → 21%) e *educação* também (5% → ... → 14%), enquanto *reduzir violência* **cai** (17% → ... → 7%) e *saúde* **cai com a renda** (24% até 1 SM → 10% no topo). Leitura defensável (à la Inglehart, materialismo × pós-materialismo): camadas **baixas** priorizam pautas **materiais e imediatas**; camadas **altas**, pautas **estruturais** — achado robusto por aparecer em duas variáveis independentes.

Recortes adicionais. O **Norte** é o único onde *emprego* (21%) supera *saúde* (19%), com *desigualdades* também alta (20%); a *violência* é regional (alta no Sudeste e Nordeste, baixa no Norte e Centro-Oeste). **Mulheres priorizam saúde muito mais** (24% vs 16%); **pretos priorizam combater preconceitos** mais que brancos (18% vs 10%). Em todos os recortes, "ampliar a participação política" permanece no fundo (1%–3%) — o desinteresse pelo processo político não é uma média que esconde subgrupos, e sim **transversal**.

3.4 Combate às fake news (P_03)

Pergunta de múltipla escolha (1 a 6 medidas), com **3.105 menções feitas por 2.000 respondentes** — percentuais sobre o total de menções. Quatro leituras se complementam:

1. **Punir mais que regular — já na medida mais citada.** Dois terços das menções (**66,9%**) são de punição/responsabilização contra **33,1%** de regulamentação. As **três medidas mais citadas são todas punitivas**: punir usuários (26,6%, a nº 1), punir empresas (21,7%) e punir políticos (18,6%).
2. **Quem responsabilizar: o usuário, não o político.** Por ator, as menções dividem-se em usuários (36,7%), empresas/plataformas (35,9%) e políticos (27,3%) — o cidadão comum é o alvo mais citado e o político, o menos.

3. **Punir indivíduos, regular plataformas.** Cruzando tipo × ator, a punição responde por **72,5% das menções sobre usuários** e 68,0% sobre políticos, caindo para **60,3% sobre empresas** — as plataformas são o ator para quem mais se admite regulação no lugar de punição direta.
4. **Preferências concentradas.** Metade dos respondentes (49,0%) citou **uma única medida** e 74,7% citaram 1 ou 2 (média ≈ 1,55); apenas 2,1% (n = 41) marcaram todas as seis.

Achado. Uma opinião pública que pede **respostas diretas e punitivas** — sobretudo dirigidas ao usuário — em vez de soluções regulatórias ou processuais.

3.5 Vontade de participar da política local (P_04)

Nível	%	n
Nenhuma vontade	78,0%	1.559
Alguma vontade	13,2%	264
Muita vontade	8,5%	169

Achado. O desengajamento declarado é expressivo e **transversal**: **78% não têm nenhuma vontade** de participar da política local; a disposição total ("alguma" + "muita") é de apenas ≈ 21,7%. Os recortes não revelam nenhum bolsão de engajamento, mas mostram quem se afasta mais ou menos:

1. **Gradiente socioeconômico — o eixo mais forte.** A disposição quase **triplica** com a escolaridade: a "nenhuma vontade" cai de 89% (baixa escolaridade) para 66% (superior completo), com a disposição subindo de ≈ 11% para 34%; a renda repete o padrão (≈ 18% → 33%). É a contraparte, na própria CESOP, do gradiente confirmado no cruzamento com o TSE (3.7.2).
2. **Idade — o mesmo U-invertido da lembrança de voto.** Os 16–17 anos têm 91% de nenhuma vontade; o engajamento atinge o pico entre 35 e 54 anos (≈ 25–26% de disposição) e cai aos 65+ (85% nenhuma).
3. **Diferenças menores, porém consistentes.** Homens declaram disposição um pouco maior que mulheres (23% vs 20%); entre os grandes grupos de raça/cor, os pretos têm a maior (26%); por região, Centro-Oeste (25%) e Sudeste (24%) lideram, e Sul e Norte ficam no piso (19%) — o lado CESOP da dissociação regional explorada em 3.7.1.
4. **Desengajamento universal.** Em **nenhum subgrupo** — nem o mais escolarizado, nem o de maior renda, nem a faixa mais ativa — a maioria deseja participar: mesmo no superior completo, 66% não têm nenhuma vontade. As diferenças entre grupos são de *grau*, não de *direção*.

3.6 Panorama eleitoral — TSE 2022

- **Comparecimento nacional: 79,40%** (abstenção: 20,60%), sobre 311,5 milhões de aptos.
- **Por escolaridade — o grande separador.** A taxa sobe de forma monotônica de **49,3% (analfabetos)** a **87,6% (superior completo)** — quase **38 pontos** de diferença (≈ 25 p.p. mesmo agrupando os menos escolarizados em "baixa escolaridade ≈ 62%"). É a maior amplitude de todo o estudo.
- **O gradiente é universal; a geografia é secundária.** O cruzamento região × escolaridade mostra que o gradiente **se repete dentro de cada região**, com as regiões **convergindo no topo** (superior completo entre 87% e 89% em todas) e **divergindo apenas na base** (analfabetos de 40% no Sudeste a 57% no Nordeste). No agregado, a diferença regional é pequena (Sul ≈ 81,0% no teto, Norte ≈ 78,1% no piso; ≈ **3 p.p.**).
- **Por idade — jovens facultativos engajados, idosos em colapso.** A curva sobe a um platô em 50–60 anos (87,6%) e depois **despenca**: 63,1% aos 70 e apenas 29,3% aos 80. Já os jovens de **16–17 (voto**

facultativo) comparecem $\approx 83\%$ — mais que os eleitores de 30 anos (80,1%). Como o eleitorado se concentra entre 25 e 50 anos, esses extremos pouco deslocam a média nacional.

- **Por gênero — efeito pequeno e condicionado pela escolaridade.** Entre analfabetos os homens comparecem mais (54% vs 45%), mas a vantagem se inverte no superior completo (88% mulheres vs 87% homens).

Achado. A escolaridade discrimina o comparecimento **muito mais** que a região (≈ 25 p.p. contra ≈ 3 p.p.) — pista de que a escolaridade, não a geografia, é o fator estruturante.

3.7 Cruzamento CESOP $\times$ TSE (núcleo do projeto)

3.7.1 Por região — *percepção e comportamento divergem* ($\rho = -0,30$)

Região	Comparecimento (TSE)	Disposição (CESOP)
Sul	$\approx 81,0\%$	18,9%
Nordeste	$\approx 80,6\%$	19,8%
Centro-Oeste	$\approx 79,0\%$	25,0%
Sudeste	$\approx 78,4\%$	23,7%
Norte	$\approx 78,1\%$	19,4%

A correlação de Spearman é **negativa** ($\rho = -0,30$). **Sul e Nordeste votam mais, mas declaram menos vontade de participar**; Centro-Oeste e Sudeste fazem o inverso. Por região, alto comparecimento **não significa** alta disposição — chegam a se opor. (Ressalva: as bases não medem os mesmos indivíduos; a comparação é *ecológica*.)

3.7.2 Por escolaridade — *percepção e comportamento se alinham* ($\rho = 1,00$)

Escolaridade	Comparecimento (TSE)	Disposição (CESOP)
Baixa escolaridade	$\approx 62\%$	$\approx 11\%$
Ensino fundamental	$\approx 77\%$	$\approx 16\%$
Ensino médio	$\approx 83\%$	$\approx 21\%$
Superior incompleto	$\approx 84\%$	$\approx 28\%$
Superior completo	$\approx 87\%$	$\approx 34\%$

A associação é **perfeita e positiva** ($\rho = 1,00$): a cada degrau de escolaridade sobem **juntos** o comparecimento real e a disposição declarada. **Esta é a dimensão em que as duas bases concordam plenamente** — o achado central do trabalho.

3.7.3 Por faixa etária — *convergência no miolo, divergência nas pontas*

No intervalo de **25 a 54 anos**, comparecimento (TSE) e disposição (CESOP) sobem juntos, com pico em 45–54. Nas extremidades, divergem: os jovens de **16–17 comparecem ($\approx 83\%$) mas têm disposição mínima ($\approx 9\%$)** — exercem o voto facultativo sem engajamento declarado correspondente; aos **65+**, ambos

caem (comparecimento para $\approx 57\%$). O formato em sino é compartilhado, mas as pontas revelam o descompasso entre **votar** e **querer participar**.

3.7.4 Abstenção × desinteresse, por região (espelho de 3.7.1)

O padrão de divergência se confirma pelo lado negativo: o **Sul** tem a **menor abstenção** ($\approx 19\%$) mas o **maior desinteresse declarado** ($\approx 81,5\%$ de "nenhuma vontade"); o **Norte**, a maior abstenção ($\approx 21,9\%$). Não há paralelismo entre abstenção e desinteresse — reforçando que, regionalmente, comportamento e percepção se dissociam.

3.7.5 Representatividade da amostra

Escolaridade	CESOP (amostra)	TSE (eleitorado)
Baixa escolaridade	3,2%	11,2%
Ensino fundamental	31,7%	29,5%
Ensino médio	40,8%	43,0%
Superior incompleto + completo	24,1%	16,3%

A amostra **sub-representa os menos escolarizados** e **sobre-representa o ensino superior** (24,1% contra 16,3% no eleitorado). Por idade, na mesma direção: **sub-representa os 65+** (9,0% vs 14,6%) e **sobre-representa os adultos de 18–34 anos** (37,9% vs 32,5%). Como a disposição e o comparecimento crescem com a escolaridade e caem entre os idosos, **os dois vieses empurram no mesmo sentido**: a amostra provavelmente **superestima** o engajamento — o desinteresse real da população tende a ser **ainda maior** que os 78% observados.

3.7.6 Fake news × comparecimento (exploratório)

Indicador de baixa variância (quase todos citam alguma medida), portanto pouco discriminante. Vale reter da seção 3.4 que a ênfase recai sobre **punição (66,9%)** mais que regulamentação — em linha com a preferência por soluções diretas observada em outras seções.

3.8 Padrões transversais (síntese analítica)

1. **A escolaridade é o eixo estruturante — e o único alinhador.** É a dimensão em que percepção (CESOP) e comportamento (TSE) concordam perfeitamente ($p = 1,00$) e a que mais discrimina o comparecimento (≈ 25 p.p. contra ≈ 3 p.p. da região). O achado é robusto por **convergência de fontes**: a **renda reproduz o mesmo gradiente** de forma independente (lembração de 25%→51%, disposição de $\approx 18\%$ →33%) e ele atravessa medidas **declaradas** e **reais**.
2. **A geografia dissocia percepção e comportamento — Sul e Norte como faces opostas** ($p = -0,30$). O **Sul** vota mais mas é o mais desinteressado; o **Norte** declara a maior lembrança de voto (41%) e tem o menor comparecimento real (78,1%). Comparecer não é o mesmo que querer participar.
3. **A idade desenha um U-invertido recorrente.** O mesmo formato aparece na lembrança de voto (3.2), na disposição declarada (3.5) e no comparecimento real (3.6): engajamento concentrado na meia-idade, queda nas duas pontas — jovens de 16–17 comparecem sem interesse correspondente; idosos caem nas duas medidas.
4. **Desengajamento participativo convergente — e preferência por soluções diretas.** 78% sem vontade (P_04), "ampliar participação" como penúltima prioridade (2%, P_02) e $\approx 65\%$ sem lembrança do voto legislativo (P_01) apontam para um vínculo fraco com a política processual; a questão das *fake*

news (3.4) reforça por outro ângulo a inclinação por respostas diretas (punir) em vez de processuais (regular).

5. **O eixo socioeconômico organiza também o conteúdo das demandas.** Não só *quanto* as pessoas se engajam, mas *o que* priorizam: camadas de menor escolaridade/renda valorizam pautas **materiais** (saúde, violência); as de maior, pautas **estruturais** (desigualdade, educação).

4. Limitações

- **Comparação ecológica.** CESOP e TSE **não medem os mesmos indivíduos**; as associações são entre **agregados** (regiões, faixas, grupos) e **não autorizam conclusões sobre indivíduos** (risco de *falácia ecológica*).
- **Correlação, número de pontos e forma da relação.** O ρ de Spearman descreve associação e direção, não causa. As correlações ecológicas apoiam-se em **poucos pontos agregados** — cinco regiões e cinco grupos de escolaridade —, funcionando como indicadores de direção e força aparente, **não como estimativas com significância estatística**. O $\rho = 1,00$ por escolaridade reflete a **monotonicidade perfeita entre cinco grupos ordenados**, não a ausência de ruído individual; a relação por idade, por ser **não monotônica**, não se resume a um único coeficiente.
- **Viés amostral (escolaridade e idade).** A CESOP sobre-representa os mais escolarizados e os adultos jovens, e sub-representa a baixa escolaridade e os idosos; como ambos os vieses empurram na mesma direção, as leituras de magnitude devem ser **conservadoras** (o engajamento real tende a ser ainda menor que o observado).
- **Recortes com baixo n.** Categorias pouco frequentes (ex.: renda "acima de 20 SM" com $n \approx 7$; faixa 16–17 com $n = 23$; raça amarela e indígena) são ilustrativas, não conclusivas.

5. Conclusão

A análise sustenta uma tese central: **no Brasil, é a escolaridade — e não a região — que organiza o engajamento político**, sendo a única dimensão em que **percepção declarada (CESOP) e comportamento eleitoral real (TSE) se alinham** ($\rho = 1,00$); a **renda reproduz o mesmo gradiente** e a **idade** funciona como um segundo eixo estrutural, concentrando o engajamento na meia-idade e deprimindo-o nas duas pontas. Geograficamente, ao contrário, as duas dimensões chegam a se **opor** ($\rho = -0,30$): o **Sul** vota muito mas quer pouco participar, e o **Norte** faz o inverso (maior lembrança declarada, menor comparecimento real).

Soma-se a isso um quadro consistente de **baixo engajamento participativo declarado** — manifesto de forma convergente em três perguntas distintas (P_01, P_02, P_04) e coerente com a preferência por **soluções diretas** (punir, no caso das *fake news*) em vez de processuais. Do ponto de vista do tema — *Percepção dos Brasileiros Acerca da Democracia* — o estudo retrata um eleitorado que **comparece às urnas** (79,4% em 2022), sustentado em parte pela obrigatoriedade, mas que, em sua maioria, **não deseja participar ativamente** da política local e **não recorda** seu voto legislativo: quer **resultados** (saúde, emprego) mais do que **tomar parte**. O trabalho cumpre o objetivo de **correlacionar uma pesquisa de opinião com uma base pública** (TSE 2022), respeitando os limites de uma comparação ecológica.

6. Reprodutibilidade

1. Os dados brutos (CESOP .SAV e TSE .csv) devem ser colocados em data/raw/ conforme o data/README.md (o arquivo do TSE, por ser grande, é distribuído via Google Drive).
2. Executar `notebooks/01_exploracao_base_parte_a.ipynb` para gerar os arquivos tratados em data/processed/.
3. Executar `notebooks/02_analises_exploratorias_parte_a.ipynb` para reproduzir as análises e as figuras (salvas em reports/imagens/).
4. Ambos os notebooks são **100% executáveis no Google Colab** (detecção automática de ambiente).

7. Referências

- CESOP — Centro de Estudos de Opinião Pública (UNICAMP). *Banco de dados do estudo 04832*.
- TSE — Tribunal Superior Eleitoral. *Perfil do Eleitorado — Comparecimento e Abstenção, Eleições Gerais de 2022*. Repositório de Dados Eleitorais.
- IBGE — Instituto Brasileiro de Geografia e Estatística. *Divisão regional do Brasil* (categorização das Grandes Regiões).
- McKinney, W. *pandas: powerful Python data analysis toolkit*.
- Hunter, J. D. *Matplotlib: A 2D Graphics Environment*; Waskom, M. *seaborn*.

8. Declaração de uso de Inteligência Artificial

Em conformidade com as diretrizes do projeto, declara-se o uso de **assistência de IA** (modelo de linguagem, via Claude Code) nas seguintes etapas: estruturação e revisão do código dos notebooks, padronização das visualizações, redação e organização deste relatório e verificação de consistência entre os achados e as figuras geradas. **Todas as decisões analíticas, a seleção das bases, a interpretação dos resultados e a validação final foram conduzidas e revisadas pelos autores.** Os valores numéricos relatados foram extraídos das análises e figuras produzidas pelos próprios notebooks do projeto.

Documento gerado para o Projeto I — EDA da disciplina de Ciência de Dados.