

Percepção dos Brasileiros Acerca da Democracia

Uma análise exploratória correlacionando opinião declarada (CESOP) e comportamento eleitoral observado (TSE 2022)

Disciplina: Ciência de Dados — Projeto I (EDA, *Exploratory Data Analysis*) **Instituição:** Instituto Mauá de Tecnologia (IMT) **Tema:** Percepção dos Brasileiros Acerca da Democracia **Bases:** CESOP/04832 (pesquisa de opinião) × TSE (perfil de comparecimento e abstenção, Eleições Gerais de 2022) **Ano:** 2026

Resumo

Este trabalho investiga a percepção dos brasileiros sobre democracia e participação política, correlacionando uma **pesquisa de opinião** do Centro de Estudos de Opinião Pública (CESOP, estudo 04832, $n = 2.000$ respondentes) com uma **base pública de comportamento eleitoral** do Tribunal Superior Eleitoral (TSE) — o perfil de comparecimento e abstenção das Eleições Gerais de 2022 ($\approx 8,8$ milhões de registros; 311,5 milhões de eleitores aptos). O pipeline de dados foi construído em Python (pandas, NumPy, pyreadstat) e as análises empregaram visualizações estatísticas (barras empilhadas, *heatmaps*, dispersão, linhas de eixo duplo) e a correlação de Spearman. O principal achado é que **a escolaridade — e não a região — é o eixo que organiza o engajamento político**: é a única dimensão em que percepção declarada e comportamento real se **alinham perfeitamente** ($\rho = 1,00$), enquanto, por região, as duas dimensões chegam a se **opor** ($\rho = -0,30$). Observa-se, ainda, um quadro consistente de **baixo engajamento participativo declarado** (78% sem vontade de participar da política local), convergente em três perguntas independentes da pesquisa.

1. Introdução

1.1 Contexto e motivação

A democracia brasileira combina **voto obrigatório** (para a maioria dos cidadãos) com níveis variados de engajamento político voluntário. Essa combinação levanta uma questão central: **o ato de votar — muitas vezes uma obrigação legal — reflete uma disposição genuína de participar da vida política?** Pesquisas de opinião capturam a *percepção e a disposição declaradas*; registros eleitorais capturam o *comportamento efetivo*. Analisar as duas dimensões em conjunto permite verificar se elas convergem ou divergem.

1.2 Problema de pesquisa

O projeto parte da seguinte pergunta norteadora:

Grupos com maior participação eleitoral real também demonstram maior disposição declarada para participar da política? Em que dimensões (região, escolaridade, idade) percepção e comportamento se alinham — ou divergem?

1.3 Objetivos

Objetivo geral. Realizar uma análise exploratória da percepção dos brasileiros sobre democracia e participação política, correlacionando-a com o comportamento eleitoral observado em 2022.

Objetivos específicos:

1. Estruturar e limpar a base de opinião (CESOP) e a base eleitoral (TSE), tornando-as comparáveis.
2. Caracterizar a amostra e descrever as percepções declaradas (lembração de voto, prioridades políticas, combate a *fake news* e vontade de participação).
3. Descrever o comparecimento e a abstenção eleitoral de 2022 por região, idade e escolaridade.
4. **Cruzar** percepção declarada (CESOP) e comportamento real (TSE) por grupos sociodemográficos, identificando padrões de convergência e divergência.

1.4 Perguntas analíticas derivadas

#	Pergunta	Seção
Q1	Qual o perfil da amostra e o que os brasileiros declaram lembrar/priorizar/desejar?	3.1–3.5
Q2	Como variam comparecimento e abstenção por região, idade e escolaridade?	3.6
Q3	Disposição declarada e comparecimento real andam juntos, por região?	3.7
Q4	E por escolaridade? E por faixa etária?	3.7
Q5	A amostra de opinião é representativa do eleitorado?	3.7

2. Materiais e Métodos

2.1 Fontes de dados

2.1.1 Base principal — CESOP/04832 (pesquisa de opinião)

- **Origem:** Centro de Estudos de Opinião Pública (CESOP/UNICAMP), estudo **04832**.
- **Formato:** arquivo SPSS (.sav), lido com a biblioteca `pyreadstat`, que preserva os rótulos de variáveis e os mapeamentos código→categoria embutidos.
- **Dimensão:** 2.000 respondentes × 30 variáveis.
- **Blocos de variáveis utilizados:**

Variável	Descrição
SEX0, FX_ID, ESCOLARIDADE, RACA, RELIGIAO	Perfil demográfico
REND1, REND2	Renda pessoal e familiar (em salários mínimos)
REGIAO, COND, PORTE	Localização e porte do município
P_01A, P_01B, P_01C	Lembrança do voto em 2022 (dep. estadual, federal, senador)
P_02_1, P_02_2, P_02_3	Prioridades políticas (1ª, 2ª e 3ª escolhas)
P_03_1 ... P_03_6	Medidas consideradas úteis contra <i>fake news</i> (múltipla)
P_04	Vontade de participar da vida política local

2.1.2 Base complementar — TSE (comportamento eleitoral)

- **Origem:** Tribunal Superior Eleitoral — *Perfil do Eleitorado: Comparecimento e Abstenção, Eleições Gerais de 2022*, arquivo nacional (...BRASIL.csv).
- **Formato:** CSV (~2,3 GB), separador `;`, encoding `latin1`.
- **Dimensão após limpeza:** **8.785.738 linhas-detalhe** (combinações de UF × município × zona × perfil demográfico).
- **Totais nacionais (2022):** 311.513.866 aptos; 247.332.217 comparecimentos; 64.181.649 abstenções.
- **Variáveis utilizadas:** SG_UF, NM_MUNICIPIO, DS_GENERO, DS_ESTADO_CIVIL, DS_FAIXA_ETARIA, DS_GRAU_ESCOLARIDADE, DS_COR_RACA, QT_APTOS, QT_COMPARECIMENTO, QT_ABSTENCAO.

Conexão conceitual entre as bases: a CESOP mede *opinião e disposição declarada*; o TSE mede *comportamento eleitoral real*. A ponte entre elas é feita por dimensões comuns (região, escolaridade, faixa etária), permitindo uma **comparação ecológica** (entre grupos agregados, não entre indivíduos).

2.2 Ferramentas e ambiente

- **Linguagem:** Python 3.
- **Bibliotecas:** `pandas` e `numpy` (manipulação), `pyreadstat` (leitura de `.SAV`), `matplotlib` e `seaborn` (visualização).
- **Formato intermediário:** **Parquet**, que preserva tipos categóricos e reduz o tamanho em disco.
- **Reprodutibilidade:** os notebooks detectam automaticamente o ambiente (**Google Colab** × local) e ajustam os caminhos — atendendo ao requisito de execução *100% no Colab*.

2.3 Pipeline de preparação dos dados (Notebook 01)

O primeiro notebook não contém análise: dedica-se inteiramente à **preparação reprodutível**.

CESOP: 1. **Carregamento** do `.SAV` com `pyreadstat` (dados + metadados). 2. **Padronização de nomes** das variáveis de pergunta (P1A → P_01A) e conversão de `DATA_ENTREVISTA` para `datetime`. 3. **Tratamento de não-resposta:** o código 99 ("Não sabe/Não respondeu") é convertido em `NaN`. A substituição é feita **por coluna** (não globalmente), de modo a **preservar** o código 98 de `REND1/REND2`

("Não tem rendimento"), que é uma **categoria válida**. 4. **Rotulagem**: aplicação dos *value labels* e conversão para o tipo `category`. 5. **Variáveis derivadas**: agregação dos 16 níveis de ESCOLARIDADE em **5 grupos ordenados** (`ESCOL_GRUPO`) e das faixas de renda em **5 faixas** (`RENDA_PESSOAL`, `RENDA_FAMILIAR`). Inclui-se uma **validação de cobertura** que detecta rótulos não mapeados (evita perdas silenciosas por divergência de grafia).

TSE: 1. **Carregamento otimizado**: leitura **apenas das colunas necessárias** (`usecols`) — essencial para caber na memória do Colab dado o volume de 2,3 GB. 2. **Limpeza**: remoção de combinações com `QT_APTOS = 0` (não contribuem para taxas), normalização de strings e conversão para `category`. 3. **Variáveis derivadas**: `TAXA_COMPARECIMENTO` e `TAXA_ABSTENCAO` (proporções) e `REGIAO` (derivada da UF pela categorização do IBGE). 4. **Agregações**: dois recortes — por **UF** (`df_tse_uf`) e por **perfil demográfico nacional** (`df_tse_perfil`). As taxas agregadas usam a **soma** das contagens (média ponderada por eleitor), e não a média das taxas-linha — evitando que zonas pequenas distorçam o indicador. 5. **Validação**: `assert` garante que todas as taxas estão no intervalo `[0, 1]` antes do salvamento.

Saídas: `cesop_clean.parquet`, `tse_clean.parquet`, `tse_uf.parquet`, `tse_perfil.parquet` e `cesop_labels.json`.

2.4 Harmonização entre as bases

Como CESOP e TSE adotam convenções diferentes, foram criadas tabelas de correspondência (Notebook 02):

- **Região**: unificação de grafias (ex.: `NORDESTE` → `Nordeste`).
- **Escolaridade**: os 8 níveis do TSE são mapeados para os 5 grupos do CESOP.
- **Faixa etária**: as idades do TSE são *bucketizadas* nas mesmas faixas do CESOP.

2.5 Técnicas estatísticas e de visualização

- **Distribuições univariadas**: frequências e percentuais, com `n` explícito.
- **Tabelas cruzadas** (`crosstab`) normalizadas por linha (composição dentro de cada grupo).
- **Visualizações**: barras horizontais, **barras empilhadas 100%**, **gráficos de pizza**, **heatmaps**, **dispersão (scatter)** e **linhas com eixo duplo (twinx)**.
- **Correlação de Spearman (ρ)**: medida de associação **monotônica** entre os agregados, apropriada para poucos pontos e relações não necessariamente lineares. Usada nos cruzamentos CESOP × TSE.
- **Cuidados metodológicos**: denominadores corretos em perguntas de múltipla escolha (percentuais sobre o **total de menções**, não de respondentes) e ordenação semântica das categorias ordinais.

3. Resultados e Discussão

Todos os percentuais e coeficientes a seguir foram obtidos diretamente das análises dos notebooks. Valores precedidos de "≈" foram lidos das figuras geradas.

3.1 Perfil da amostra (CESOP, $n = 2.000$)

- **Sexo:** 51,7% feminino, 48,3% masculino.
- **Faixa etária:** concentração em adultos — 25–34 anos (22,9%) e 35–44 anos (21,2%); jovens de 16–17 anos representam apenas 1,1%.
- **Raça/cor:** parda (46,0%) e branca (42,3%) somam quase 90%; preta (10,4%), amarela (0,9%), indígena (0,4%).
- **Escolaridade:** ensino médio predomina (40,8%); baixa escolaridade é rara na amostra (3,2%) — ponto retomado na análise de representatividade (3.7).

3.2 Lembrança do voto em 2022 (P_01A/B/C)

Cargo	Lembra ("Sim")	Não lembra	Não votou
Deputado(a) estadual	29,8%	64,6%	5,5%
Deputado(a) federal	29,4%	65,0%	5,6%
Senador(a)	29,6%	64,9%	5,5%

Achado. A lembrança é **praticamente idêntica entre os três cargos** ($\approx 30\%$): a maioria ($\approx 65\%$) **não recorda em quem votou** para o Legislativo em 2022. Não há o gradiente "estadual < federal < senador" que se poderia supor. Nos recortes sociodemográficos, a lembrança tende a ser **maior entre os mais escolarizados** e nas faixas adultas.

3.3 Prioridades políticas (P_02)

Na **primeira escolha**, os temas mais citados foram:

Prioridade	% (1ª escolha)	n
Melhorar saúde	20,0%	400
Gerar empregos	14,7%	294
Reduzir desigualdades	14,3%	286
Reduzir violência	12,5%	250
Combater preconceitos	11,7%	233
Melhorar educação	11,1%	222
Preservar valores familiares	5,1%	103
Taxar grandes fortunas	2,2%	45
Ampliar participação política	2,0%	40
Defender igualdade de gênero	1,9%	38

Achado. Predominam pautas de **serviços e bem-estar** (os seis primeiros temas somam $\approx 84\%$). Em contraste, **"ampliar a participação política"** é a **penúltima prioridade (2,0%)** — primeiro indício do desengajamento processual confirmado na seção 3.5.

3.4 Combate às *fake news* (P_03)

Pergunta de múltipla escolha (1 a 6 medidas por respondente). Agrupando as medidas por tipo de ação (percentual sobre o total de menções):

- **Punição / responsabilização: 66,9%** (2.077 menções)
- **Regulamentação: 33,1%** (1.028 menções)

Achado. Predomina, por dois para um, a preferência por **sancionar** em vez de **normatizar** — uma inclinação por respostas diretas/punitivas.

3.5 Vontade de participar da política local (P_04)

Nível	%	n
Nenhuma vontade	78,0%	1.559
Alguma vontade	13,2%	264
Muita vontade	8,5%	169

Achado. O desengajamento declarado é expressivo: **78% não têm nenhuma vontade** de participar da política local; a disposição total ("alguma" + "muita") é de apenas $\approx 21,7\%$. Esse resultado reforça a baixa prioridade dada à participação (3.3).

3.6 Panorama eleitoral — TSE 2022

- **Comparecimento nacional: 79,40%** (abstenção: 20,60%).
- **Por região:** Sul ($\approx 81,0\%$) e Nordeste ($\approx 80,6\%$) lideram; Norte ($\approx 78,1\%$) e Sudeste ($\approx 78,4\%$) ficam abaixo da média. **Amplitude pequena: ≈ 3 pontos percentuais.**
- **Por escolaridade:** gradiente **forte e crescente** — de $\approx 62\%$ (baixa escolaridade) a $\approx 87\%$ (superior completo). **Amplitude grande: ≈ 25 pontos percentuais.**
- **Por idade:** formato de sino, com pico em 45–64 anos (≈ 87 – 88%) e quedas nas pontas — efeito do **voto facultativo**: 65+ comparecem $\approx 57\%$ e jovens de 16–17, $\approx 83\%$.

Achado. A escolaridade discrimina o comparecimento **muito mais** que a região (25 p.p. contra 3 p.p.) — pista de que a escolaridade, não a geografia, é o fator estruturante.

3.7 Cruzamento CESOP × TSE (núcleo do projeto)

3.7.1 Por região — percepção e comportamento divergem ($\rho = -0,30$)

Região	Comparecimento (TSE)	Disposição (CESOP)
Sul	$\approx 81,0\%$	18,9%
Nordeste	$\approx 80,6\%$	19,8%
Centro-Oeste	$\approx 79,0\%$	25,0%
Sudeste	$\approx 78,4\%$	23,7%
Norte	$\approx 78,1\%$	19,4%

A correlação de Spearman é **negativa** ($\rho = -0,30$). **Sul e Nordeste votam mais, mas declaram menos vontade de participar**; Centro-Oeste e Sudeste fazem o inverso. Ou seja, **por região, alto comparecimento não significa alta disposição** — chegam a se opor.

3.7.2 Por escolaridade — percepção e comportamento se alinham ($\rho = 1,00$)

Escolaridade	Comparecimento (TSE)	Disposição (CESOP)
Baixa escolaridade	$\approx 62\%$	$\approx 11\%$
Ensino fundamental	$\approx 77\%$	$\approx 16\%$
Ensino médio	$\approx 83\%$	$\approx 21\%$
Superior incompleto	$\approx 84\%$	$\approx 28\%$
Superior completo	$\approx 87\%$	$\approx 34\%$

A associação é **perfeita e positiva** ($\rho = 1,00$): a cada degrau de escolaridade sobem **juntos** o comparecimento real e a disposição declarada. **Esta é a dimensão em que as duas bases concordam plenamente.**

3.7.3 Por faixa etária — convergência no miolo, divergência nas pontas

No intervalo de **25 a 54 anos**, comparecimento (TSE) e disposição (CESOP) sobem juntos, com pico em 45–54. Nas extremidades, divergem: os jovens de **16–17 comparecem ($\approx 83\%$) mas têm disposição mínima ($\approx 9\%$)** — exercem o voto facultativo sem engajamento declarado correspondente; aos **65+**, ambos caem.

3.7.4 Abstenção × desinteresse, por região (espelho de 3.7.1)

O padrão de divergência se confirma pelo lado negativo: o **Sul** tem a **menor abstenção** ($\approx 19\%$) mas o **maior desinteresse declarado** ($\approx 81,5\%$ de "nenhuma vontade").

3.7.5 Representatividade da amostra

Escolaridade	CESOP (amostra)	TSE (eleitorado)
Baixa escolaridade	3,2%	11,2%
Ensino fundamental	31,7%	29,5%
Ensino médio	40,8%	43,0%
Superior incompleto	9,8%	5,4%
Superior completo	14,3%	10,9%

A amostra **sub-representa os menos escolarizados** e **sobre-representa o ensino superior** (24,1% contra 16,3% no eleitorado). Como a disposição cresce com a escolaridade (3.7.2), isso implica que a amostra provavelmente **superestima** o engajamento — o desinteresse real da população tende a ser **ainda maior** que os 78% observados.

3.8 Padrões transversais (síntese analítica)

1. **A escolaridade é o eixo estruturante e o único alinhador.** É a dimensão em que percepção (CESOP) e comportamento (TSE) concordam perfeitamente ($p = 1,00$), e a que mais discrimina o comparecimento (≈ 25 p.p.).
2. **A geografia dissocia as duas dimensões** ($p = -0,30$): votar muito não implica querer participar — o "paradoxo do Sul".
3. **Desengajamento participativo convergente** em três perguntas independentes: 78% sem vontade (P_04), "ampliar participação" como penúltima prioridade (2%, P_02) e $\approx 65\%$ sem lembrança do voto legislativo (P_01).
4. **O paradoxo dos jovens de 16–17:** comparecem bastante, mas têm a menor disposição declarada.

4. Limitações

- **Comparação ecológica.** CESOP e TSE **não medem os mesmos indivíduos**; as associações são entre **agregados** (regiões, faixas, grupos) e **não autorizam conclusões sobre indivíduos** (risco de *falácia ecológica*).
- **Correlação $\neq$ causalidade.** Os coeficientes de Spearman descrevem **associação e direção**, não relações de causa e efeito.

- **Natureza amostral e viés de escolaridade.** A CESOP é uma amostra de opinião (≈ 2.000 respondentes) que sobre-representa os mais escolarizados; leituras de magnitude devem ser conservadoras.
 - **Recortes com baixo n.** Categorias pouco frequentes (ex.: alguns grupos de raça/cor) devem ser interpretadas com cautela.
-

5. Conclusão

A análise sustenta uma tese central: **no Brasil, é a escolaridade — e não a região — que organiza o engajamento político**, sendo a única dimensão em que **percepção declarada (CESOP) e comportamento eleitoral real (TSE) se alinham** ($p = 1,00$). Geograficamente, as duas dimensões chegam a se **opor** ($p = -0,30$): alto comparecimento não significa alta disposição para participar, como ilustra o caso do Sul. Soma-se a isso um quadro consistente de **baixo engajamento participativo declarado**, manifesto de forma convergente em três perguntas distintas da pesquisa.

Do ponto de vista do tema — *Percepção dos Brasileiros Acerca da Democracia* — o estudo mostra um eleitorado que **comparece às urnas** (79,4% em 2022), mas que, em sua maioria, **não deseja participar ativamente** da política local e **não recorda** seu voto legislativo. A participação eleitoral, sustentada em parte pela obrigatoriedade, **não se traduz** automaticamente em engajamento cívico declarado — e essa tradução depende fortemente da escolaridade. O trabalho cumpre o objetivo de **correlacionar uma pesquisa de opinião com uma base pública** (TSE 2022), respeitando os limites de uma comparação ecológica.

6. Reprodutibilidade

1. Os dados brutos (CESOP `.sav` e TSE `.csv`) devem ser colocados em `data/raw/` conforme o `data/README.md` (o arquivo do TSE, por ser grande, é distribuído via Google Drive).
 2. Executar `notebooks/01_exploracao_base_parte_a.ipynb` para gerar os arquivos tratados em `data/processed/`.
 3. Executar `notebooks/02_analises_exploratorias_parte_a.ipynb` para reproduzir as análises e as figuras (salvas em `reports/imagens/`).
 4. Ambos os notebooks são **100% executáveis no Google Colab** (detecção automática de ambiente).
-

7. Referências

- CESOP — Centro de Estudos de Opinião Pública (UNICAMP). *Banco de dados do estudo 04832*.
 - TSE — Tribunal Superior Eleitoral. *Perfil do Eleitorado — Comparecimento e Abstenção, Eleições Gerais de 2022*. Repositório de Dados Eleitorais.
 - IBGE — Instituto Brasileiro de Geografia e Estatística. *Divisão regional do Brasil* (categorização das Grandes Regiões).
 - McKinney, W. *pandas: powerful Python data analysis toolkit*.
 - Hunter, J. D. *Matplotlib: A 2D Graphics Environment*; Waskom, M. *seaborn*.
-

8. Declaração de uso de Inteligência Artificial

Em conformidade com as diretrizes do projeto, declara-se o uso de **assistência de IA** (modelo de linguagem, via Claude Code) nas seguintes etapas: estruturação e revisão do código dos notebooks, padronização das visualizações, redação e organização deste relatório e verificação de consistência entre os achados e as figuras geradas. **Todas as decisões analíticas, a seleção das bases, a interpretação dos resultados e a validação final foram conduzidas e revisadas pelos autores.** Os valores numéricos relatados foram extraídos das análises e figuras produzidas pelos próprios notebooks do projeto.

Documento gerado para o Projeto I — EDA da disciplina de Ciência de Dados.